



НИУ ВШЭ


Факультет Компьютерных Наук

Москва 2026

Долгосрочное прогнозирование событий с помощью диффузионных генеративных моделей и метода DeTPP

Тюпляев Никита Алексеевич
natyuplyaev@edu.hse.ru

Постановка задачи



- Каждое событие описывается парой (t, y) , где t - временная метка, y - тип события
- Прогнозирование последовательностей событий на горизонте (marked temporal point processes)
- По наблюдаемой истории требуется предсказать не только следующее событие, но целый будущий горизонт событий



Актуальность и сложность исследования

Прикладной контекст

- Последовательности событий возникают во многих цифровых системах
- Примеры: покупки пользователей, транзакции, действия на онлайн-платформах
- Необходимо уметь предсказывать не только следующее событие, но и целый будущий горизонт событий

В чем состоит сложность

- События происходят нерегулярно во времени
- Ошибки по времени, типам и порядку событий тесно связаны
- Высокое качество при предсказании следующего события не гарантирует качества на длинном горизонте

Почему next-event prediction недостаточен

Ошибка прогноза = время + тип события + количество + порядок

- **Время**
 - событие предсказано слишком рано или слишком поздно
- **Тип события**
 - верное время, но неверная категориальная метка
- **Количество событий**
 - модель пропускает события или добавляет лишние
- **Порядок**
 - локальные перестановки получают штраф при позиционном loss



Ограничения существующих подходов

Подход	Преимущество	Ограничения
Авторегрессионные модели	предсказывают события последовательно	накапливают ошибки на длинном горизонте
Diffusion	моделирует будущий фрагмент целиком	сохраняет позиционную привязку
DeTPP (SoTA)	использует matching алгоритм и снимает жесткий порядок предсказаний	не строит отдельное совместное представление будущего фрагмента



Цель и задачи

Исследовать возможность объединения диффузионной модели и механизма сопоставления (matching) метода DeTPP для прогнозирования последовательностей событий на горизонте

Этапы работы

- Анализ существующих подходов
- Изучение бенчмарка HoTPP, используемых датасетов и метрик
- Разработка гибридной архитектуры
- Оценка полученной модели и сравнение с baseline
- Анализ поведения модели и ограничений предложенного подхода



Benchmark

HoTPP benchmark

- Эксперименты проводятся в рамках benchmark-а HoTPP
- HoTPP задает единый протокол сравнения моделей долгосрочного прогнозирования
- Benchmark включает стандартные датасеты, метрики и разбиения на выборки

arXiv:2406.14341v4 [cs.LG] 2 Aug 2025

HoTPP Benchmark: Are We Good at the Long Horizon Events Forecasting?

Ivan Karpukhin
Sber AI Lab
iakarpukhin@sberbank.ru

Foma Shipilov
Skoltech, Sber AI Lab
foma.shipilov@skoltech.ru

Andrey Savchenko
Sber AI Lab
avladsavchenko@sberbank.ru

Abstract

Forecasting multiple future events within a given time horizon is essential for applications in finance, retail, social networks, and healthcare. Marked Temporal Point Processes (MTPP) provide a principled framework to model both the timing and labels of events. However, most existing research focuses on predicting only the next event, leaving long-horizon forecasting largely underexplored. To address this gap, we introduce *HoTPP*, the first benchmark specifically designed to rigorously evaluate long-horizon predictions. We identify shortcomings in widely used evaluation metrics, propose a theoretically grounded *T-mAP* metric, present strong statistical baselines, and offer efficient implementations of popular models. Our empirical results demonstrate that modern MTPP approaches often underperform simple statistical baselines. Furthermore, we analyze the diversity of predicted sequences and find that most methods exhibit mode collapse. Finally, we analyze the impact of autoregression and intensity-based losses on prediction quality, and outline promising directions for future research. The HoTPP source code, hyperparameters, and full evaluation results are available at <https://github.com/ivan-chai/hotpp-benchmark>.

1 Introduction

Internet activity, e-commerce transactions, retail operations, clinical visits, and numerous other aspects of our lives generate vast amounts of data in the form of timestamps and related information. In the era of AI, it is crucial to develop methods capable of handling these complex data streams. We refer to this type of data as Event Sequences (ESs).

Event sequences differ fundamentally from other data types. Unlike tabular data [29], ESs include timestamps and possess an inherent order. In contrast to time series data [16], ESs are characterized by irregular time intervals and additional data fields, such as event types. These differences necessitate the development of specialized models and evaluation practices.

Irregularly spaced timestamps are commonly modeled via Temporal Point Processes (TPP) [24]. Assigning categorical labels to these events leads to the Marked Temporal Point Process (MTPP) formalism. Since most event-sequence data can be viewed as MTPPs augmented with additional fields [18], accurately modeling event times and labels remains a central challenge in the broader event-stream (ES) domain.

In practice, a common question arises: what events will occur, and when, within a specific *time horizon*? Forecasting multiple future events presents unique challenges that differ from traditional



Данные

Датасет	Train	Val	Test	Всего записей	Средняя длина	Общее кол-во событий	Кол-во классов
Amazon	6.45K	922	1.85K	9.22K	43.6	402K	16
StackOverflow	1.4K	401	401	2.20K	64.2	141K	22
Retweet	19.5K	1.95K	1.95K	23.4K	56.4	1.3M	3

Метрики

Entropy:

$$H = - \sum p(x) \log p(x)$$

Next-item accuracy:

$$Acc = \frac{1}{M} \sum_{i=1}^M \mathbb{I}[\hat{y}_{i+1} = y_{i+1}]$$

T-mAP (Temporal Mean Average Precision): основная метрика HoTPP для оценки прогноза на горизонте. Учитывает качество предсказания времени, типа события и уверенности модели для всех событий внутри будущего окна

Метрики: T-mAP




Figure 1: T-mAP evaluation pipeline. Unlike previous approaches, T-mAP evaluates sequences of variable lengths within the prediction horizon. It further improves performance assessment by analyzing label distributions rather than relying on fixed predictions.

Метрики: T-mAP






Figure 3: T-mAP computation pipeline.


Базовый подход: RMTPP (авторегрессия)




Базовый подход: диффузия




Базовый подход: диффузия




Базовый подход: диффузия



Базовый подход: диффузия



(a) RNN-based



(b) MLP-based

Почему чистой диффузии может быть недостаточно

Next-K target $\neq$ horizon target


Диффузия:

- генерирует фиксированные K будущих событий
- обучается через позиционное восстановление: k-я позиция $\leftrightarrow$ k-е истинное событие
- не имеет явного presence score для отбора событий внутри горизонта


Но при оценке качества на горизонте:

- Нужна оценка событий внутри временного окна
- Число событий на горизонте заранее неизвестно
- Важны не только времена и типы, но и количество предсказанных событий

Базовый подход: DeTPP




Базовый подход: DeTRP




Базовый подход: DeTPP

DeTPP: обучение через сопоставление событий

- модель параллельно предсказывает **K кандидатов** будущих событий
- строится оптимальное сопоставление между истинными и предсказанными событиями
- **Matching loss** учитывает ошибку по времени (MAE) и типу события для найденных пар (CE)
- **Presence loss** штрафует лишние кандидаты и поддерживает нужные (BCE)
- **DeTPP loss = Matching loss + Presence loss**



(a) Pairwise loss: wrong matching



(b) DEF loss: correct matching

Базовый подход: DeTRP

$$\mathcal{L}(y, \hat{y})_{\text{matching}} = \min_{\sigma \in \mathcal{A}} \left[\sum_{i=1}^T \mathcal{L}_{\text{pair}}(y_i, \hat{y}_{\sigma(i)}) + \mathcal{L}_{\text{BCE}}(\sigma, \hat{y}) \right], \quad (4)$$

where $\mathcal{A}$ is the set of all possible alignments between the ground truth and predicted sequences and σ represents a specific alignment. The optimal matching is computed using the Hungarian algorithm (Kuhn 1955), which has a cubic computational complexity with respect to the sequence length. The pairwise loss $\mathcal{L}_{\text{pair}}$ is similar to the negative log-likelihood of the ground truth event y_i given the predicted distribution $\hat{y}_{\sigma(i)}$:

$$\mathcal{L}_{\text{pair}}(y_i, \hat{y}_{\sigma(i)}) = |t_i - \hat{t}_{\sigma(i)}| - \log \hat{p}_{\sigma(i)}(l_i), \quad (5)$$

where $y = (t, l)$ is a ground truth event, $\hat{t}$ is the predicted timestamp, and $\hat{p}(l)$ is the predicted probability of the correct label. The binary cross-entropy $\mathcal{L}_{\text{BCE}}$ trains the model to predict the occurrence probability of events:

$$\mathcal{L}_{\text{BCE}}(\sigma, \hat{y}) = - \sum_{i \in \sigma} \log \hat{o}_i - \sum_{i \notin \sigma} \log(1 - \hat{o}_i), \quad (6)$$

Базовый подход: DeTPP inference и калибровка

- Модель выдает K кандидатов
- На inference остаются только кандидаты с высокой вероятностью события ($>$ определенного порога)
- Пороги отбора калибруются на validation
- После фильтрации события сортируются по предсказанному времени
- Калибровка влияет на число предсказанных событий и качество T-mAP



Спасибо за внимание!
