Последние тенденции в искусственном интеллекте

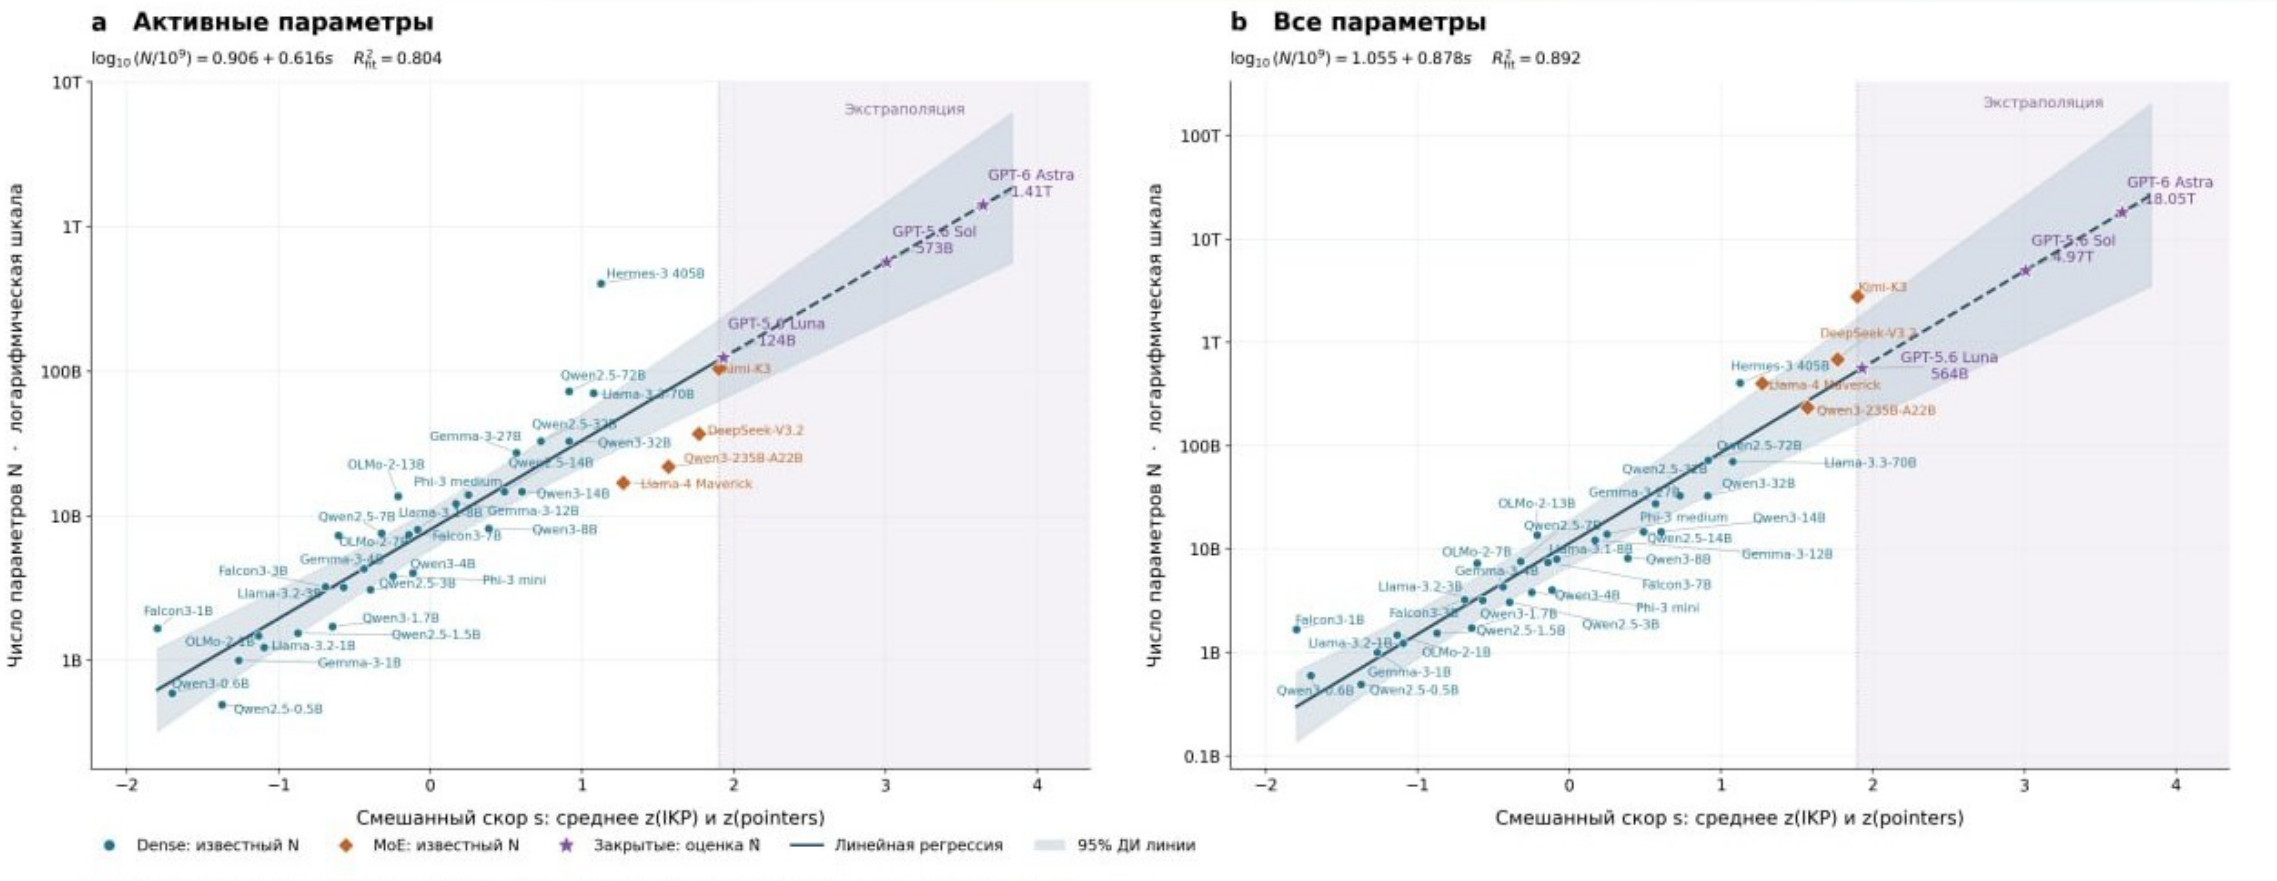
Иван Оселедец

AIRI/МГУ

Стохастика, искусственный интеллект
и финансовая математика

14 октября 2026

Размер LLM: от миллиардов к триллионам



Фиолетовые звёзды: оценки по пробам, а не раскрытые размеры

Вероятность текста и следующего токена

Текст, словарь токенов и веса модели

$$X = (x_1, \ldots, x_T) \in \mathcal{V}^T, \quad \mathcal{V}: \text{ словарь}, \quad \theta: \text{ веса}$$

$$X^{(1)}, \ldots, X^{(N)} \overset{\text{i.i.d.}}{\sim} P_\star, \quad T = |X|, \quad N: \text{ число текстов}$$

Для текста из трёх токенов

$$p_\theta(x_1, x_2, x_3) = p_\theta(x_1)\, p_\theta(x_2 \mid x_1)\, p_\theta(x_3 \mid x_1, x_2)$$

$$x_{<t} = (x_1, \ldots, x_{t-1}), \qquad \sum_{v \in \mathcal{V}} p_\theta(v \mid x_{<t}) = 1$$

AIRI

Cross-entropy даёт явный градиент ошибки

Наблюдён токен с индексом 2 в словаре. Логиты — выход перед softmax.

$$z = (\ln 2, \ln 3, \ln 5) \quad \Longrightarrow \quad p = \mathrm{softmax}(z) = (0.2, 0.3, 0.5)$$

$$\ell = -\log p_y, \qquad \frac{\partial \ell}{\partial z_v} = p_v - \mathbf{1}\{v = y\}$$

$$y = 2: \qquad \nabla_z \ell = (0.2, -0.7, 0.5)$$

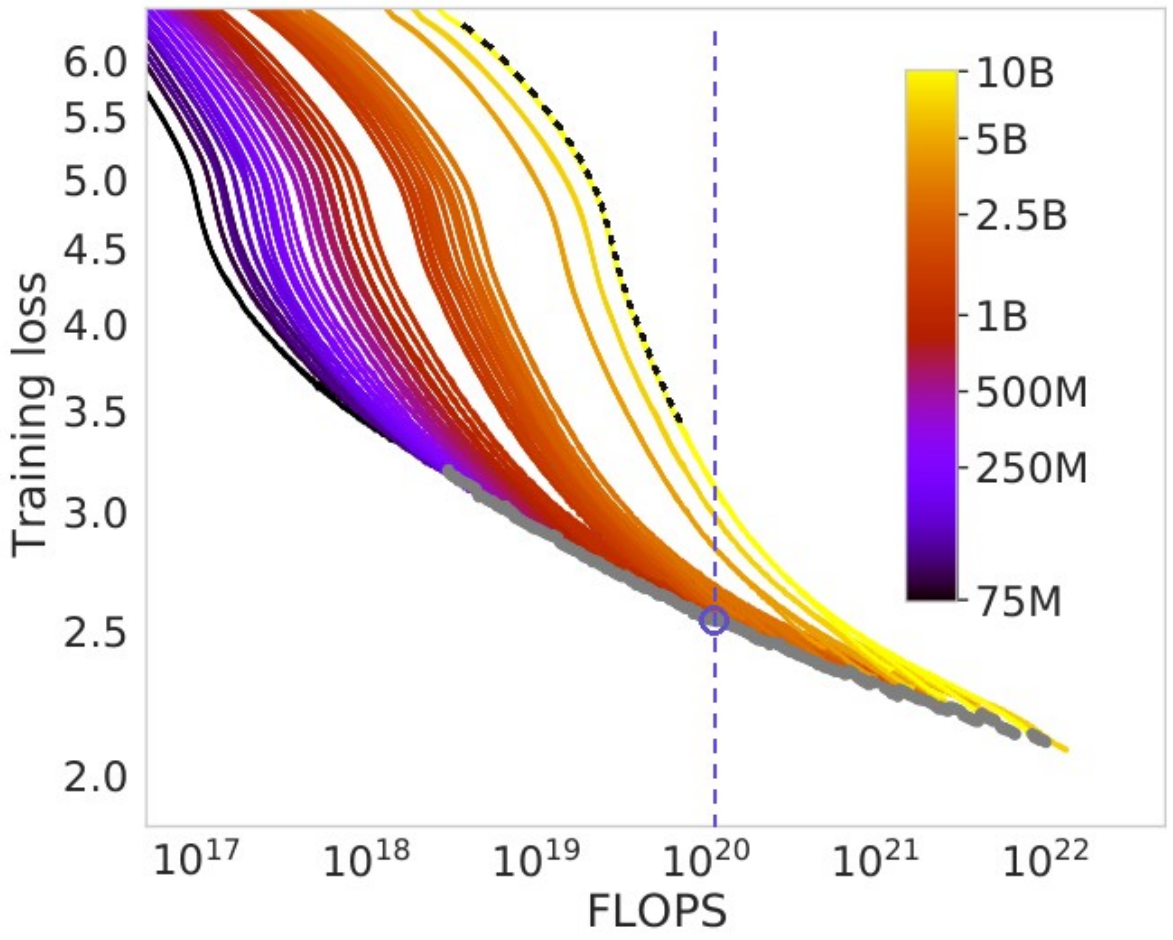
По цепному правилу получаем градиент весов

$$\nabla_\theta \ell = \sum_v \frac{\partial \ell}{\partial z_v} \nabla_\theta z_v(\theta)$$

$$\theta^+ = \theta - \eta \nabla_\theta \ell, \qquad \eta > 0: \text{ длина шага}$$

AIRI

Кривые обучения и выбор при заданном бюджете



По вертикали: training log-loss токена

По горизонтали: накопленные FLOPs

Чёрный пунктир — один запуск. Цвет задаёт размер, для него проверены 4 длительности.

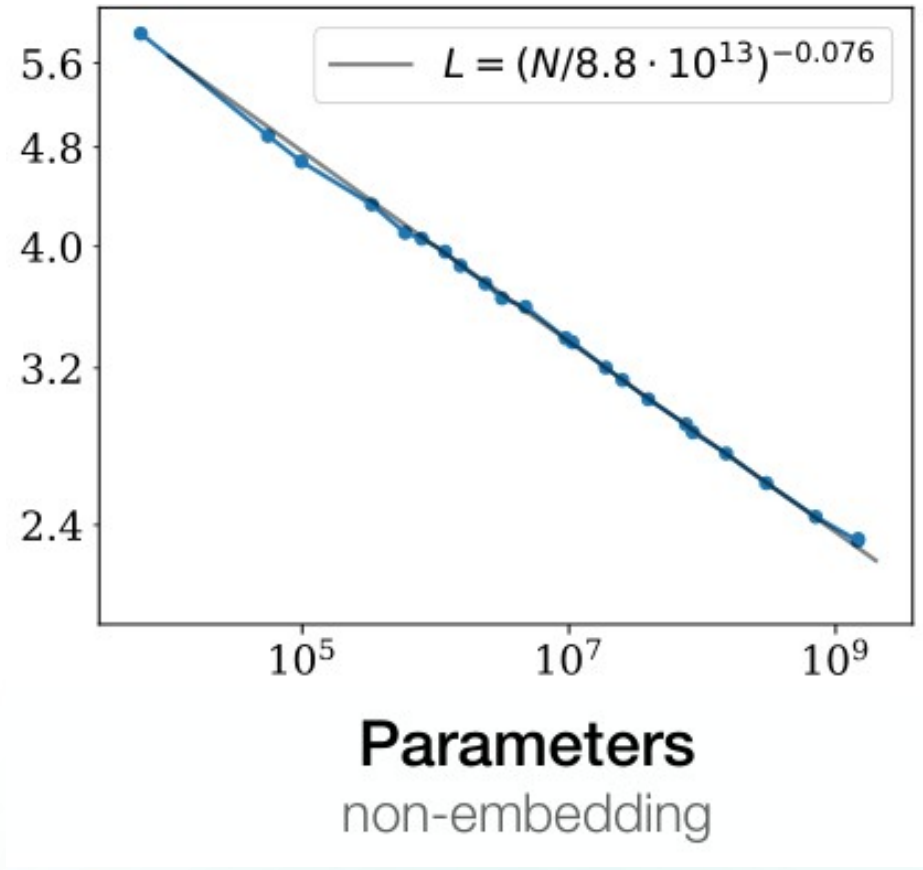
$$C_0 = 10^{20}\ \text{FLOPs}$$

$$\ell_{\min}(C_0) = \min_{\text{запуски}} \ell(C_0)$$

AIRI

Scaling law по числу параметров

По вертикали: test log-loss



Kaplan: обучение до сходимости, данных достаточно

$$N = m: \text{ параметры без embedding}$$

$$\mathcal{L}(m) \approx (m_0/m)^{\alpha}, \quad \alpha \approx 0.076$$

$$\log \mathcal{L} \approx -\alpha \log m + \alpha \log m_0$$

Показатель и масштаб подбираются по экспериментам

AIRI

Модель и данные при фиксированном бюджете

Hoffmann: совместная аппроксимация для плотных Transformer

$$\widehat{\mathcal{L}}(m, D) = \underbrace{E}_{\text{предел}} + \frac{A}{m^{\alpha}} + \frac{B}{D^{\beta}}$$

m : параметры, D : токены; E, A, B, α, β : константы fit

$$C \approx 6mD = \text{const}, \qquad A, B, \alpha, \beta > 0$$

$$\frac{d\widehat{\mathcal{L}}}{d \log m} = 0 \quad \Longrightarrow \quad \frac{\alpha A}{m^{\alpha}} = \frac{\beta B}{D^{\beta}}$$

$$m_{\star}(C) \propto C^{\frac{\beta}{\alpha+\beta}}, \qquad D_{\star}(C) \propto C^{\frac{\alpha}{\alpha+\beta}}$$

AIRI

Attention: обмен между позициями

Transformer 2017: обучаемая таблица и позиционный вектор

$$H^{(0)}_{j,:} = E[x_j] + r_j, \qquad E \in \mathbb{R}^{|\mathcal{V}| \times d}, \quad r_j \in \mathbb{R}^d$$

Далее вход — выход предыдущего блока. Проекции обучаются.

$$Q = HW_Q, \qquad K = HW_K, \qquad V = HW_V$$

Запросы Ключи Передаваемые значения

$$A = \mathrm{softmax}_j\left(\frac{QK^\top}{\sqrt{d_k}} + M\right), \qquad \boxed{Y = AV}$$

$$\sum_{j \le t} A_{tj} = 1 \quad \text{для каждого } t, \qquad d_k = \dim q_t = \dim k_j$$

$$M_{tj} = 0 \quad (j \le t), \qquad M_{tj} = -\infty \quad (j > t)$$

AIRI

Один запрос собирает три вектора в один

Математический пример одной головы $d_k = 1, \qquad d_v = 2$

Значения $v_1 = (1, 0), \quad v_2 = (0, 1), \quad v_3 = (1, 1)$

Запрос и ключи $q = 1, \qquad (k_1, k_2, k_3) = (0, \ln 2, \ln 7)$

Веса softmax $$a = \frac{(e^0, e^{\ln 2}, e^{\ln 7})}{1 + 2 + 7} = (0.1, 0.2, 0.7)$$

$$y = aV = (0.1, 0.2, 0.7) \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix}$$

$$y = (0.1 + 0.7,\ 0.2 + 0.7) = (0.8, 0.9)$$

AIRI

От attention к вероятности токена

Упрощённый блок: одна голова, без нормировок

Остаточное сложение $$U = H + YW_O, \qquad W_O \in \mathbb{R}^{d_v \times d}$$

Два слоя с поэлементной нелинейностью

$$H_{\text{next}} = U + \sigma(UW_1 + b_1)W_2 + b_2$$

После повторения блоков берём последний вектор

$$h_t^{\text{out}} = H_{t,:}^{\text{out}}, \qquad z = h_t^{\text{out}} W_{\text{vocab}} \in \mathbb{R}^{|\mathcal{V}|}$$

$$p_\theta(v \mid x_{\le t}) = \text{softmax}(z)_v = \frac{e^{z_v}}{\sum_{u \in \mathcal{V}} e^{z_u}}$$

Сколько данных нужно, чтобы выучить модель?

Ученик видит N текстов. Меморизация не гарантирует точность закона.

Известные веса teacher использует экспериментатор для анализа.

$$P_\star \xrightarrow{N \text{ i.i.d. texts}} D = (X^{(1)}_{1:L}, \ldots, X^{(N)}_{1:L}) \longrightarrow Q_D$$

Тексты независимы. Ученик восстанавливает закон той же длины L.

$$\mathrm{TV}(P, Q) = \frac{1}{2} \sum_{x_{1:L}} |P(x_{1:L}) - Q(x_{1:L})|$$

Риск усредняем по случайности обучающей выборки D

$$\mathbb{E}_D \, \mathrm{TV}(P_\star, Q_D) \leq \varepsilon$$

AIRI

Сжатие задаёт конечный каталог моделей

На той же длине L: сжимаем матрицы внимания и MLP

$$\underset{m\times n}{W} \approx \underset{m\times r}{U}\,\underset{r\times n}{V^{\mathsf{T}}}, \qquad mn \longrightarrow mr + nr$$

$$D(r) = D_0 + r\sum_{\ell}(m_\ell + n_\ell) = D_0 + b_{\text{arch}} r$$

D_0 — число несжимаемых весов

Ограниченные факторы и чувствительность задают TV-покрытие:

$$\mathcal{C}_r(\eta) = \{Q_1, \ldots, Q_M\}, \qquad \min_j \mathrm{TV}(Q, Q_j) \le \eta,$$

$$\log M \le D(r)\log(1 + LC_r/\eta).$$

C_r зависит от радиусов факторов и чувствительности logits к весам.

AIRI

Выбираем модель по эмпирическим частотам

Каталог фиксирован до выборки; множества сравнения общие

$$A_{ij} = \{x_{1:L} : Q_i(x_{1:L}) > Q_j(x_{1:L})\}, \qquad 1 \le i, j \le M$$

Считаем частоты этих множеств в N наблюдаемых текстах

$$P_{\text{emp}}(A) = \frac{1}{N} \sum_{k=1}^{N} \mathbf{1}\{X_{1:L}^{(k)} \in A\}$$

Для каждого кандидата: наибольшее расхождение; затем минимум

$$\Delta_i = \max_{1 \le j,k \le M} |Q_i(A_{jk}) - P_{\text{emp}}(A_{jk})|,$$

$$\hat{i} = \arg\min_{1 \le i \le M} \Delta_i, \qquad Q_D := \widehat{P}_{N,r} = Q_{\hat{i}}.$$

AIRI

Выбор по частотам ограничивает ошибку TV

Сравним с ближайшим элементом того же каталога

$$i_\star \in \arg\min_{1\le i\le M} \mathrm{TV}(P_\star, Q_i), \qquad d_\star := \mathrm{TV}(P_\star, Q_{i_\star})$$

Ошибка частот

$$Z_N := \max_{1\le j,k\le M} |P_{\mathrm{emp}}(A_{jk}) - P_\star(A_{jk})|$$

Выбор минимума

$$\Delta_{\hat{i}} \le \Delta_{i_\star} \le d_\star + Z_N$$

$$A = A_{\hat{i}i_\star}: \quad \mathrm{TV}(Q_D, Q_{i_\star}) = Q_D(A) - Q_{i_\star}(A) \le \Delta_{\hat{i}} + \Delta_{i_\star} \le 2d_\star + 2Z_N$$

Неравенство треугольника

$$\mathrm{TV}(P_\star, Q_D) \le d_\star + \mathrm{TV}(Q_{i_\star}, Q_D) \le 3d_\star + 2Z_N$$

Сжатый teacher: $P_\star^{(r)}, \qquad A_\star(r) := \mathrm{TV}(P_\star, P_\star^{(r)}), \qquad d_\star \le A_\star(r) + \eta$

AIRI

Баланс ошибок даёт оценку числа текстов

Если ошибка сжатия убывает степенным образом:

$$A_\star(r) := \mathrm{TV}(P_\star, P_\star^{(r)}) \le a r^{-\alpha}, \qquad a, \alpha > 0$$

При фиксированной L применяем лемму Хёффдинга

$$\mathbb{E}_D \,\mathrm{TV}(P_\star, \widehat{P}_{N,r}) \le 3A_\star(r) + 3\eta + \sqrt{\frac{2\log(2M^2)}{N}}$$

$$\underbrace{r \asymp (a/\varepsilon)^{1/\alpha}}_{a r^{-\alpha} \asymp \varepsilon} \qquad \underbrace{N \asymp D(r)\varepsilon^{-2}}_{\sqrt{D(r)/N} \asymp \varepsilon}$$

$$N_{\mathrm{suff}}(\varepsilon) \;\lesssim_{\log}\; D_0 \varepsilon^{-2} + b_{\mathrm{arch}} a^{1/\alpha} \varepsilon^{-(2+1/\alpha)}$$

До полного ранга; точность покрытия порядка ε. Логарифмы скрыты.
Достаточно для этого оценивателя; сходимость SGD не утверждается.

AIRI

Одиночные знаки не определяют закон пары

Теперь цель длиннее данных: по одному знаку восстанавливаем пару

$L = 1, \quad T = 2$ $\qquad D = (X_1^{(1)}, \ldots, X_1^{(N)}), \qquad \mathcal{L}_+(D) = \mathcal{L}_-(D) = (1/2, 1/2)^{\otimes N}$

$P_{+,2}$

$X_1 \backslash X_2$	$+1$	-1
$+1$	$3/8$	$1/8$
-1	$1/8$	$3/8$

$\sum_{X_2}$ →

$P_{+,1} = P_{-,1}$

$1/2$
$1/2$

← $\sum_{X_2}$

$P_{-,2}$

$X_1 \backslash X_2$	$+1$	-1
$+1$	$1/8$	$3/8$
-1	$3/8$	$1/8$

$$3/8 + 1/8 = 1/8 + 3/8 = 1/2$$

$$\mathrm{TV}(P_{+,2}, P_{-,2}) = \frac{1}{2} \cdot 4 \cdot \left| \frac{3}{8} - \frac{1}{8} \right| = \frac{1}{2}$$

AIRI

Короткие данные не определяют длинный закон

$$D \sim P_L^{\otimes N}, \qquad T = L + 1, \qquad Q_{D,L+1} = \mathrm{Learn}(D)$$

$$x_i \in \{-1, 1\}, \qquad 0 < \rho < 1, \qquad \theta = \pm\rho$$

$$P_{\theta,L+1}(x_{1:L+1}) = 2^{-(L+1)} \left(1 + \theta \prod_{i=1}^{L+1} x_i\right)$$

$$P_{\theta,L}(x_{1:L}) = \sum_{x_{L+1}=\pm 1} 2^{-(L+1)} \left(1 + \theta \prod_{i=1}^{L+1} x_i\right) = 2^{-L}$$

$$\rho = \mathrm{TV}(P_{+,L+1}, P_{-,L+1}) \leq \mathrm{TV}(P_{+,L+1}, Q_{D,L+1}) + \mathrm{TV}(Q_{D,L+1}, P_{-,L+1})$$

Закон выборки одинаков: усредняем треугольник по одним данным

$$\max_{\sigma=\pm} \mathbb{E}_{D \sim P_{\sigma,L}^{\otimes N}} \mathrm{TV}(P_{\sigma,L+1}, Q_{D,L+1}) \geq \rho/2 \qquad \forall N$$

AIRI

Retrieval: вернуть последнее значение

Фиксируем семейство задач и измеряем точность отдельных ответов

$$\text{query key} = [69, 51] \qquad \text{episode } 0 \text{ of } 512$$

Показаны 3 записи одного ключа из 32; позиции с нуля

Номер записи	Значение	Позиция при 221	Позиция при 16 384
10	[49, 21]	70	5 073
28	[61, 39]	187	14 094
31	**[25, 55]**	**208**	**16 085**

$$\text{last value} = [25, 55] \quad \Rightarrow \quad \text{answer} = [25, 55]$$

Whole-value: верны оба токена значения

AIRI

RoPE поворачивает пары координат

Каждая пара координат запроса и ключа имеет свою частоту

$$R(\varphi) = \begin{pmatrix} \cos\varphi & -\sin\varphi \\ \sin\varphi & \cos\varphi \end{pmatrix} \qquad \tilde{q}_t = R(t\omega)q_t, \qquad \tilde{k}_j = R(j\omega)k_j$$

$$\tilde{q}_t^\top \tilde{k}_j = q_t^\top R((j-t)\omega)k_j$$

Global NoPE: этот поворот не применяем $\tilde{q}_t = q_t, \qquad \tilde{k}_j = k_j$

Local: окно 128, включая текущую позицию $\max(0, t-127) \le j \le t$

Global: все доступные позиции $0 \le j \le t$

Позиции нумеруются с нуля

AIRI

Масштаб и нормировка задают веса внимания

Математический пример: логиты

$$z = (0, 2)$$

$$\mathrm{softmax}(z) \approx (0.1192,\ 0.8808)$$

Entmax 1.5 $p_j = (z_j/2 - \tau)_+^2$

$$\sum_j p_j = 1: \quad \tau = 0, \quad p = (0, 1)$$

$$(z)_+ = \max(z, 0)$$

$$a_h = \log(1 + e^{r_h})$$

r_h — обучаемый параметр

Обучаемые функции $\beta_{h,t} = \beta_h(u_t), \qquad \gamma_{h,t} = \gamma_h(u_t)$

Глобальные головы MQMTAR

$$s_j = \cos(q_t, k_j)$$

$$s \longmapsto z = a_h s \qquad s \longmapsto z = \lambda_{h,t} s$$

Обучаемый скаляр	Адаптивный масштаб
Softmax	Adaptive softmax
Entmax 1.5	**ASEntmax**

$$\lambda_{h,t} = 1 + \beta_{h,t}[\log(n_t + 1)]^{\gamma_{h,t}}$$

u — состояние после LayerNorm перед attention; h — голова

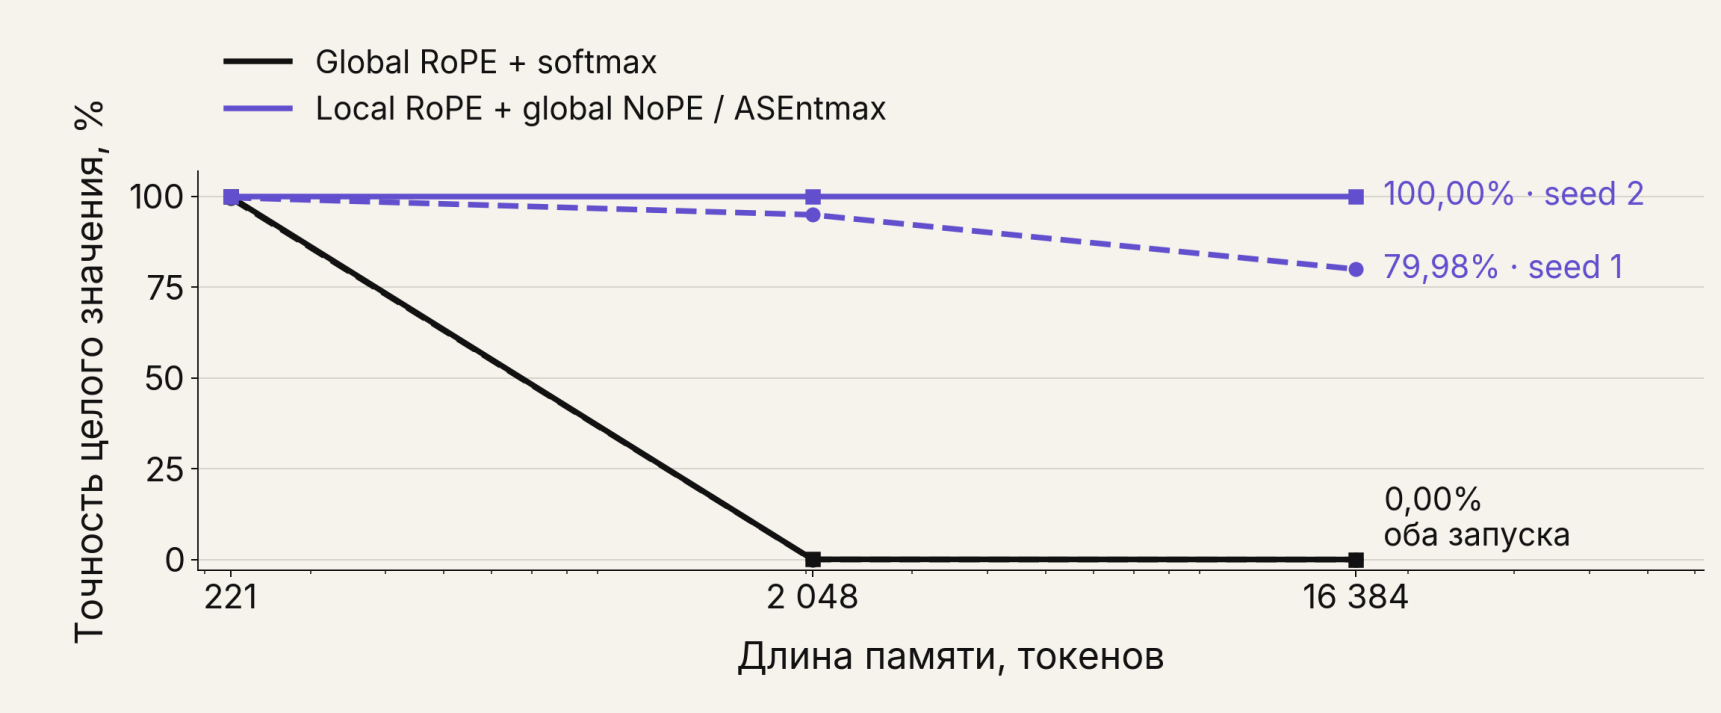
n — число токенов доступного префикса

AIRI

Перенос двух полных рецептов

Те же 512 эпизодов; растянуты только промежутки между записями

Обучение: память 192–221 токен; полный вход до 249



MQMTAR: три запуска каждого варианта

Без перезаписей: 16, 64 или 128 пар, ключ и значение — по 2 токена

Фиксированы 4 local RoPE + softmax и 4 global NoPE

В global меняются нормировка и масштаб; scores — cosine

Точность целого значения, %; память 952 → 16 384 токена

Вариант	Seed 1	Seed 2	Seed 3
Softmax	2,41 → 0,00	2,67 → 0,00	26,17 → 0,07
Entmax 1.5	98,50 → 98,50	2,86 → 2,67	99,54 → 99,67
Adaptive softmax	2,60 → 3,26	2,54 → 3,26	2,08 → 2,02
ASEntmax	**99,93 → 100**	**99,80 → 99,93**	**99,67 → 99,80**

384 эпизода × 4 запроса; 1,28 млн обучающих примеров на запуск

Распространённая схема обучения LLM

$$\theta_0 \xrightarrow{\text{pretraining}} \theta_{\text{pre}} \xrightarrow{\text{SFT}} \theta_{\text{SFT}} \xrightarrow{\text{alignment}} \theta_{\text{align}}$$

Данные	Обучающий критерий
Текст корпуса	$-\sum_t \log p_\theta(x_t \mid x_{<t}) \longrightarrow \min$
SFT: запрос и эталонный ответ	$(x, y^\star): \quad -\sum_{t=1}^{\lvert y^\star \rvert} \log p_\theta(y_t^\star \mid x, y_{<t}^\star) \longrightarrow \min$
Alignment: выбран вариант RL	Обучение по проверяемому результату своих решений

Reasoning: поиск внутри одной генерации

Countdown: каждое число использовать ровно один раз

$$89,\ 48,\ 99,\ 28,\ 5,\ 39 \quad \longrightarrow \quad 14$$

E2H Reasoner. Сокращённый перевод одной цепочки

$$\tau:\ \text{вся цепочка}, \qquad \theta = \text{const при генерации}$$

Получилось неверное значение. Можно попробовать другую разность.

$$48 - 99 + 89 - 5 - 28 + 39 = 44 \neq 14$$

Продолжаем вычисление с оставшимися числами.

$$89 - 48 - 99 + 5 + 28 + 39 = 14$$

Награда за правильность финального ответа

$$\tau = (\text{рассуждение}, y), \qquad y = \text{final answer}$$

$$y = 89 - 48 - 99 + 28 + 5 + 39$$

Программа проверяет: операции, каждое число один раз, значение равно цели

$$R(x, \tau) = \mathbf{1}\{\text{valid}(y) \wedge \text{eval}(y) = 14\} = 1$$

Промежуточная ветка не получает отдельной награды

От награды к градиенту вероятности

REINFORCE. Вся цепочка получает одну награду.

$$x: \text{ запрос}, \qquad \theta: \text{ веса}, \qquad \tau \sim \pi_\theta(\cdot \mid x)$$

$$J(\theta) = \mathbb{E}_\tau R(x, \tau) = \sum\nolimits_\tau \pi_\theta(\tau \mid x) R(x, \tau)$$

Проверяющая функция при обновлении не зависит от весов

$$\begin{aligned}
\nabla_\theta J &= \sum_\tau R(x, \tau)\, \nabla_\theta \pi_\theta(\tau \mid x) \\
&= \sum_\tau R(x, \tau)\, \pi_\theta(\tau \mid x)\, \nabla_\theta \log \pi_\theta(\tau \mid x) \\
&= \mathbb{E}_\tau [R(x, \tau)\, \nabla_\theta \log \pi_\theta(\tau \mid x)]
\end{aligned}$$

Baseline и общий сигнал для токенов

Baseline $b(x)$ — опорная награда для запроса, оценённая независимо от текущей цепочки

$$\begin{aligned}\mathbb{E}_\tau[b(x)\nabla_\theta \log \pi_\theta(\tau \mid x)] &= b(x)\nabla_\theta \sum\nolimits_\tau \pi_\theta(\tau \mid x) \\ &= b(x)\nabla_\theta 1 = 0\end{aligned}$$

τ_t : токен, $\tau_{<t}$: предыдущие токены

$$\log \pi_\theta(\tau \mid x) = \sum\nolimits_t \log p_\theta(\tau_t \mid x, \tau_{<t})$$

Один коэффициент перед суммой токенных градиентов

$$\nabla_\theta J = \mathbb{E}_\tau\left[\big(R(x,\tau) - b(x)\big) \sum\nolimits_t \nabla_\theta \log p_\theta(\tau_t \mid x, \tau_{<t})\right]$$

Что задаёт знак обновления?

Математическая иллюстрация: baseline равен половине

$$b(x) = 0.5, \quad R(x, \tau_\star) = 1 \quad \Longrightarrow \quad \hat{g}_\star = +0.5\, \nabla_\theta \log \pi_\theta(\tau_\star \mid x)$$

Показанная цепочка прошла проверку

$$R(x, \tau) = 0 \quad \Longrightarrow \quad \hat{g} = -0.5\, \nabla_\theta \log \pi_\theta(\tau \mid x)$$

Для непрошедшей проверки цепочки знак противоположен

$$\theta^+ = \theta + \eta \hat{g}, \qquad \eta > 0 : \text{ длина шага}$$

AIRI

GRPO: вклад групповых наград в градиент

Математическая иллюстрация: 8 цепочек для одного запроса

$$r_i = R(x, \tau_i) \in \{0, 1\}, \qquad i = 1, \ldots, 8$$

$$\mathbf{r} = (1, 1, 1, 1, 0, 0, 0, 0), \qquad \bar{r} = \frac{4 \cdot 1 + 4 \cdot 0}{8} = \frac{1}{2}$$

$$\tilde{r}_i = r_i - \bar{r}, \qquad \tilde{\mathbf{r}} = \frac{1}{2}(1, 1, 1, 1, -1, -1, -1, -1)$$

При весах генерации — только вклад награды

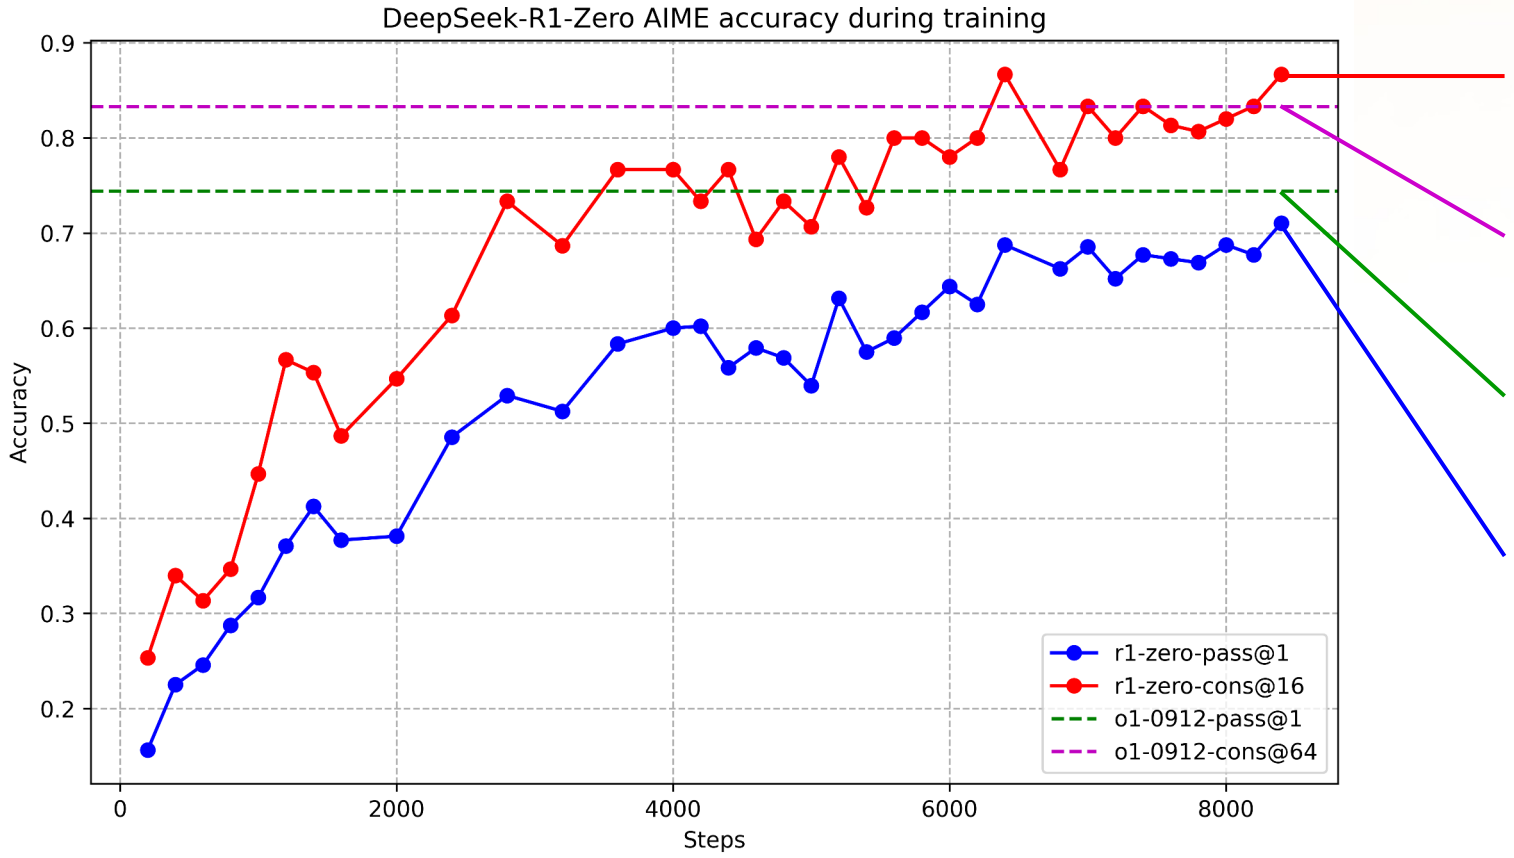
$$\hat{g}_R \propto \sum_{i=1}^{8} \tilde{r}_i \, \nabla_\theta \log \pi_\theta(\tau_i \mid x)$$

При 0 или 8 успехах центрированный сигнал равен нулю

AIRI

DeepSeek-R1-Zero: рост точности на AIME 2024

$$\text{DeepSeek-V3-Base} \xrightarrow{\text{RL (GRPO)}} \text{R1-Zero}$$



Без промежуточного reasoning-SFT

Голосование 16 ответов

o1: голосование 64 ответов

o1: один ответ

Один ответ R1-Zero

$$15.6\% \longrightarrow 71.0\%$$

По горизонтали: шаги RL

AIRI

SGD может требовать экспоненциального числа шагов

Diligent Learner, §4: отрицательный результат для SFT

$$x \sim \mathrm{Unif}\{-1,1\}^{2m}, \qquad \pi \in S_{2m}, \qquad v_1 = x$$

Неизвестная перестановка выбирает m из 2m входных знаков

$$v_2 = \prod_{j=1}^{m} x_{\pi(j)}$$

$$v_i = v_{i-1} x_{\pi(i)}, \quad i = 3, \ldots, m-2,$$

$$y = v_{m-2}$$

Для обучения первого перехода методом SGD

$$T_{\mathrm{SGD}} = \Omega(\exp(m))$$

Нижняя оценка для заданного семейства задач и предпосылок SGD

AIRI

Teacher forcing скрывает ошибки выполнения

Правильное автономное выполнение

$$v_2 \xrightarrow{\times x_{\pi(3)}} v_3 \xrightarrow{\times x_{\pi(4)}} \cdots \longrightarrow y$$

Первый знак ошибочен; последующие переходы вычислены правильно

$$-v_2 \xrightarrow{\times x_{\pi(3)}} -v_3 \xrightarrow{\times x_{\pi(4)}} \cdots \longrightarrow -y$$

Teacher forcing:
правильный предыдущий шаг

$$\hat{y} = v_{m-3}^{\text{gold}} x_{\pi(m-2)} = y$$

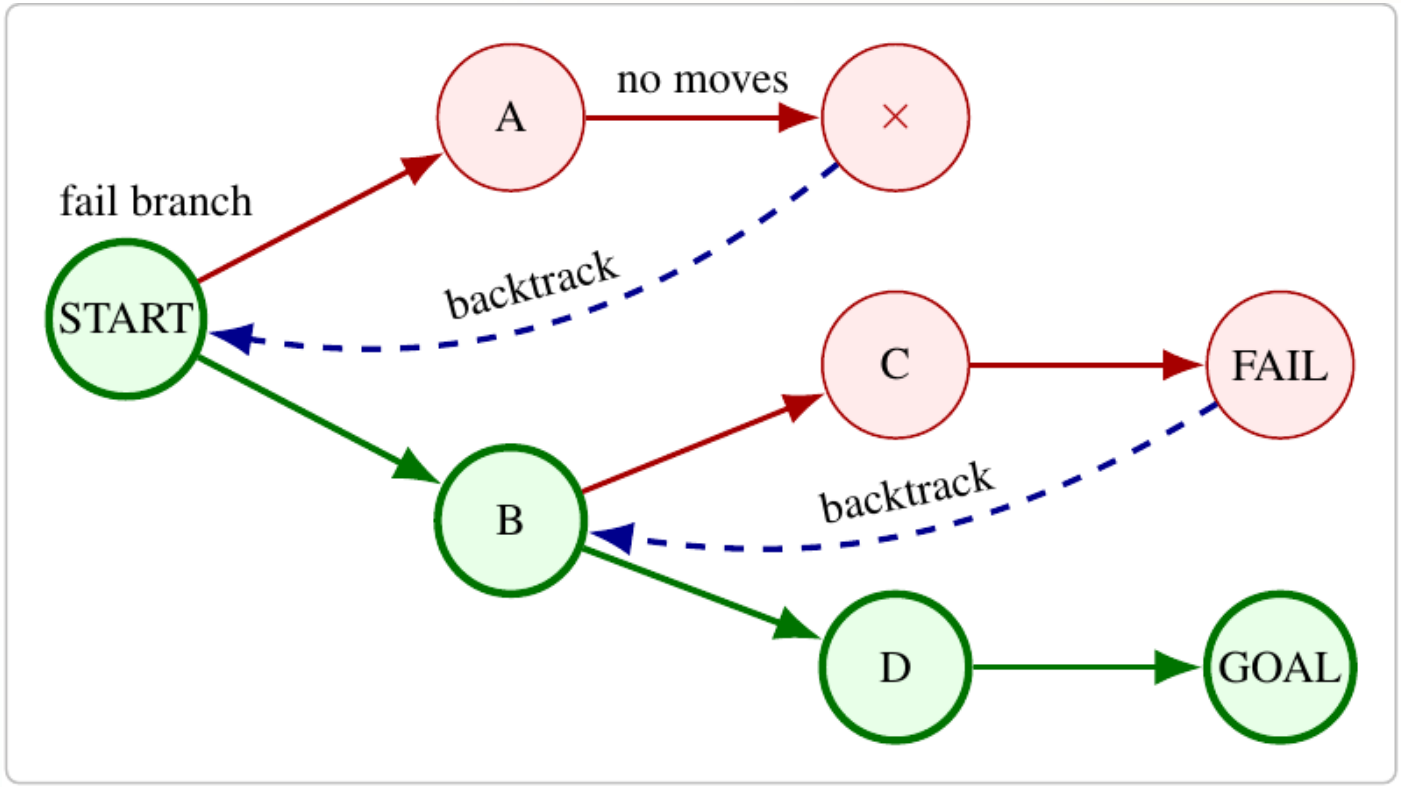
Автономное выполнение
n независимых компонент

$$\Pr(\widehat{\mathbf{y}} = \mathbf{y}) \approx (1/2)^n$$

AIRI

Pyligent: скрытый граф

Цель — достигнуть GOAL; видны исходящие рёбра текущей вершины



В START видны A, B

После MOVE B видны C, D

В C открывается ребро к FAIL

Неудачная ветка становится примером для SFT

Исполненные переходы $\mathrm{START}_0 \longrightarrow B_1 \longrightarrow C_2$

В C раскрыто наблюдение: доступен только FAIL

Вход для SFT $[\mathrm{START}, B, C, \mathrm{obs}(C \to \mathrm{FAIL})]$

Целевой ответ <backtrack>1 Failure reached</backtrack>

SFT обновляет веса по паре «неудачный префикс → возврат»

Runtime исполняет возврат к B, обрезая контекст

$$[\mathrm{START}, B, C, \mathrm{obs}(C \to \mathrm{FAIL})] \longmapsto [\mathrm{START}, B]$$

Pyligent: 3,8% → 76,5% решённых задач

Qwen3-0.6B · 300 train / 200 test · 3 запуска · до 30 шагов

Модель / обучение	Успех, %	Число шагов
Base	0,0 ± 0,0	29,85 ± 0,05
Base + thinking	0,2 ± 0,3	14,69 ± 0,26
Gold-only SFT	3,8 ± 1,2	24,21 ± 1,22
Pyligent	**76,5 ± 2,3**	**10,96 ± 0,43**

Среднее ± стандартное отклонение по трём запускам

Агент = LLM + Harness

LLM + Harness = Агент

Рассуждение
и выбор действий

Инструменты, контекст,
память и исполнение

Агент — система, которая сама выбирает действия и использует инструменты для достижения цели

Текст и структурированный вызов

Инструмент — внешняя программа с описанными аргументами и результатом

Обычное сообщение

«В таблице 1 результат Pyligent — 76,5%»

Схема вызова read_pdf

```
type: tool_call
name: read_pdf
arguments:
  arxiv: "2607.07492"
  table: 1
```

Harness исполняет вызов и обновляет контекст

Агент выбирает следующий шаг по цели и наблюдениям

Контекст до исполнения

```
user: результат Pyligent?
assistant: tool_call
read_pdf(
  arxiv="2607.07492", table=1)
```

Harness запускает read_pdf

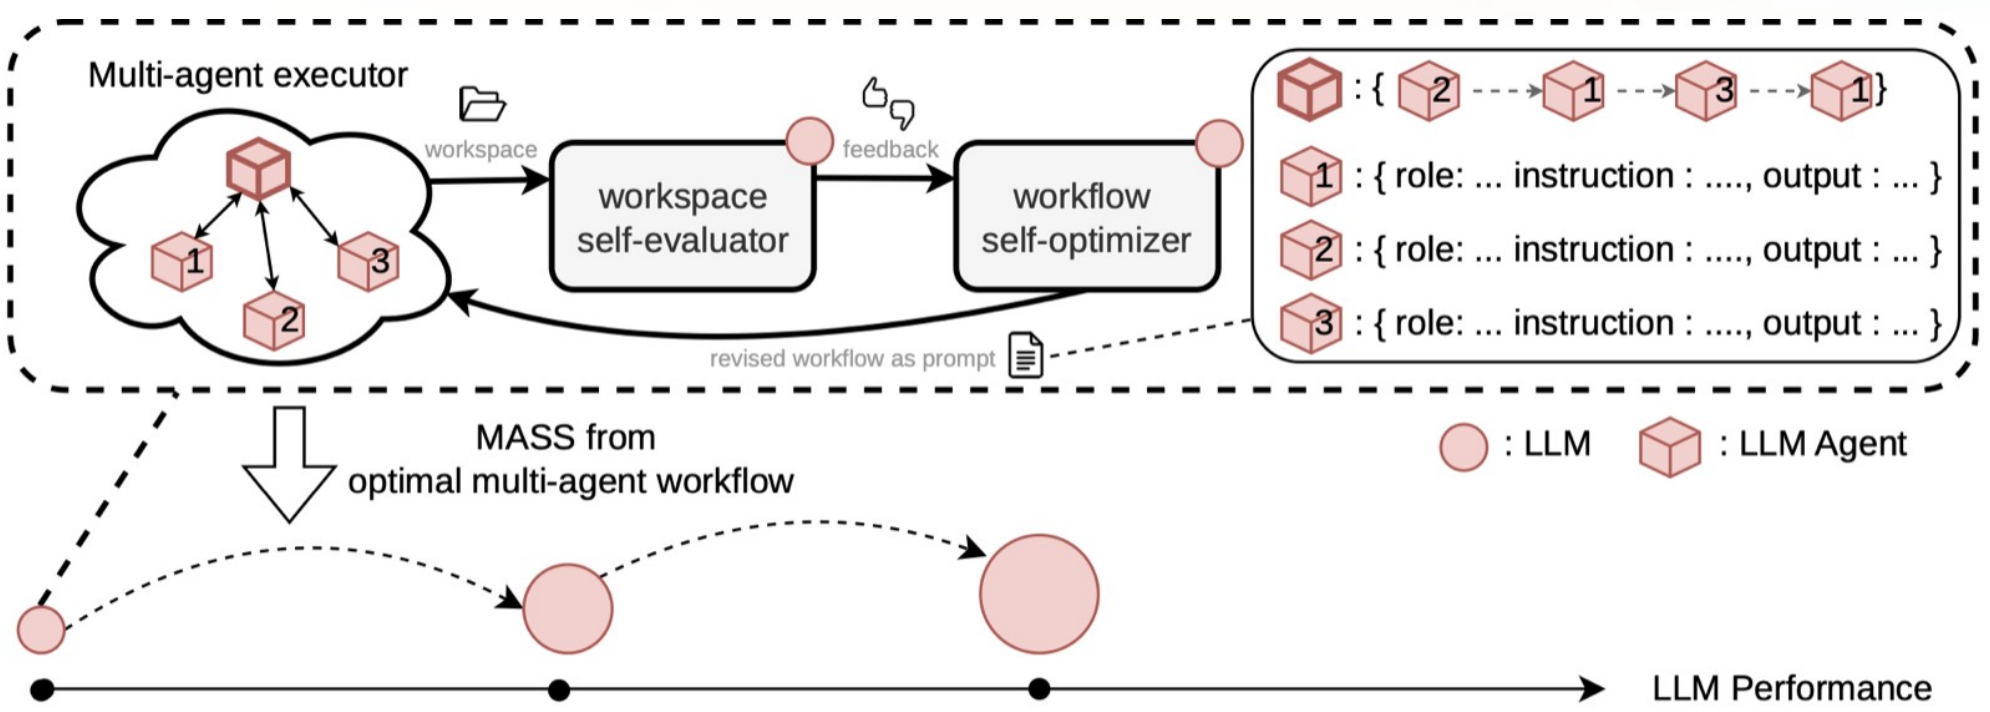
Следующий вход LLM

История слева
+ tool result:
Table 1, Pyligent: 76,5%

LLM → assistant: «В Table 1 — 76,5%»

Рой агентов учится совместной работе

MASS: оптимизация взаимодействий и обучение по траекториям



[Sakana AI: arxiv.org/abs/2610.12176](arxiv.org/abs/2610.12176)

AI Researcher: генератор статей

Prompt2Edge: драфт фреймворка → эксперименты → статья

Proposer

Гипотеза

Librarian

Литература
и данные

Оркестратор

задачи ↔
выходы

MLE Solver

Эксперименты:
код и результаты

Reviewer

Замечания
к результатам

Writer

Текст,
рисунки
LaTeX / PDF

Статья



Prompt2Edge – An Autonomous Machine Learning System for Edge Devices

Aleksei Stepin, ITMO University, St. Petersburg, Russia
Vladislav Kulikov, ITMO University, St. Petersburg, Russia
Boris Tolstokulakov, ITMO University, St. Petersburg, Russia
Mikhail Mozikov, AXXX, Moscow, Russia; Trusted AI Center, RAS, Moscow, Russia; mozikov@axxx.tech
Ilya Makarov, AXXX, Moscow, Russia; Research Center of the Artificial Intelligence Institute, Innopolis University, Innopolis, Russia; makarov@axxx.tech

AutoML для
edge-устройств

AIRI

Задача OCC: компактное ядро до 4B

Optimal Cognitive Core

Управлять инструментами и исполнителями
на длинной траектории с обратной связью



Обучаем в исполняемых средах с проверяемым результатом

Наше исследование: оркестрация с двумя инструментами

Decomposer: малая модель управляет исполнителями

Менеджер формулирует подзадачу и выбирает действие

Создать субагента

Передать текст подзадачи

Ждать

Получить результат исполнителя

Инструменты среды доступны только субагенту

Обучаем выбор подзадач и порядок взаимодействий

AIRI

Обучение оркестрации: 36,6% → 65,4% решённых задач

Наш Decomposer: Qwen3.5-4B, SFT по DeepSeek V4 Flash

1 140 Workplace Assistant + 622 Toolathlon Gym

Менеджер	pass@1, %
Без менеджера	15,4
Qwen3.5-4B до SFT	36,6
Наш 4B после SFT	**65,4**
DeepSeek V4 Flash	68,0

Workplace Assistant: исполнитель Gemma 4 E4B фиксирован

OCC.Tool: один раунд обучения

Code agent пишет шаблон: выбор строк БД и цепочка вызовов

Генератор подставляет строки и ID → задача + gold

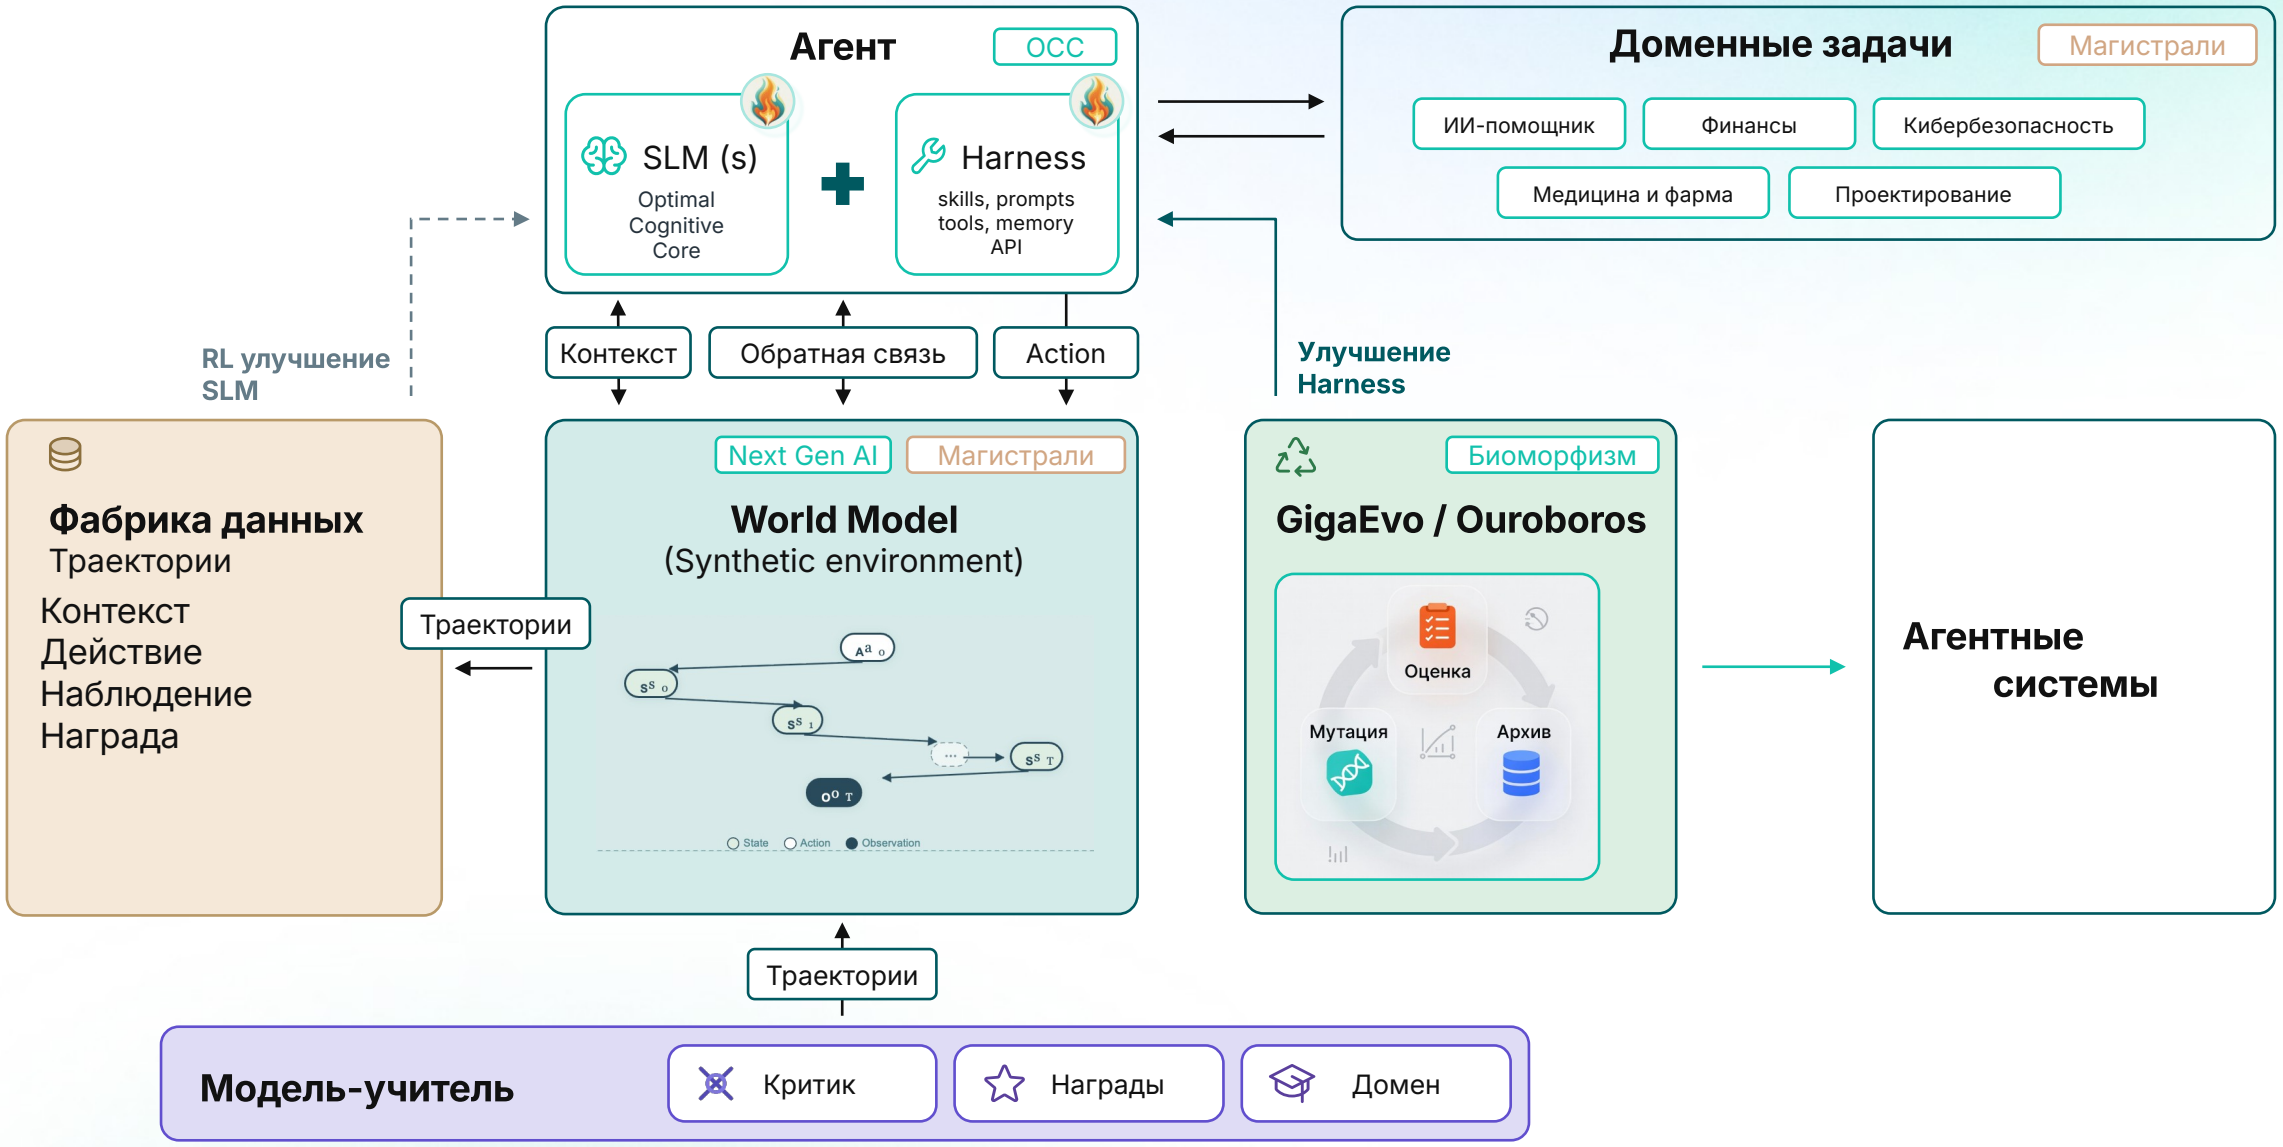
gold — эталонные вызовы $V(\tau_{\text{gold}}) = 1, \qquad V([]) = 0$

8 попыток ученика → проверка вызовов, аргументов и итоговой БД

Успехов из 8	Обновление ученика	Изменение шаблона
0	Учитель → verifier → SFT	Тот же шаблон
1–4	**GRPO на всех 8 попытках**	**Тот же шаблон**
5–8	Учитель → verifier → SFT	Усложнить шаблон

Обновлённые ученик и шаблон → следующий раунд

LLM + Harness + World Model



Эволюция программ использует независимую проверку



GigaEvo: результаты на Jigsaw

Фиксированный классификатор Qwen2.5-14B-Instruct

Что эволюционирует	Train AUC	Test AUC
Исходный вариант	0,673	0,670
Промпт	0,794	0,783
Агентная программа	**0,811**	**0,803**

LANTERN: поиск связи в OEIS

Определения A132440 и A039755 → векторы LLM

Ранжирование → гипотеза → численная и аналитическая проверка

P : матрица Паскаля, M : B-числа Стирлинга

$$P_3 = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 2 & 1 \end{pmatrix} \qquad M_3 = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 4 & 1 \end{pmatrix}$$

$$M_3^{-1} P_3^2 M_3 = \begin{pmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 0 & 4 & 1 \end{pmatrix}$$

$$M^{-1} P^2 M = I + 2T, \qquad T = \log P$$

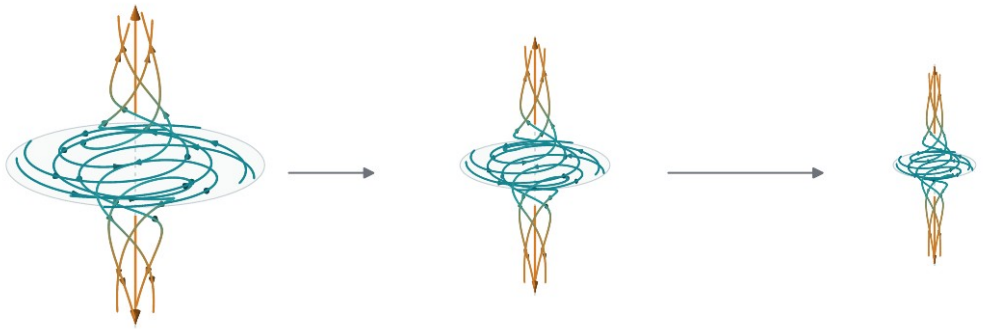
AIRI

Сингулярность совместима с конечной энергией

Навье—Стокс в 3D с гладкой внешней силой

Сжатие ведущего ядра

$$\tau = 1 - t \downarrow 0, \qquad 0 < h < \frac{1}{100}$$



$$t_1 < t_2 < t_3 < 1$$

Радиус и высота

$$\ell_r \asymp \tau^{1/2}, \qquad \ell_z \asymp \tau^{1/2-h}$$

Характерная скорость

$$U \asymp \tau^{-1/2-h} \longrightarrow \infty$$

Масштаб энергии ведущего ядра

$$E_{\text{core}} \asymp U^2 \ell_r^2 \ell_z \asymp \tau^{-1-2h}\, \tau^{3/2-h} = \tau^{1/2-3h} \longrightarrow 0$$

Группам агентов: решение Эйлера + сводки результатов

Доказательство Навье—Стокса → формализация и проверка в Lean

AIRI